

统计计算 张楠 2019秋: Variance Reduction: Antithetic Variables

(返回 [统计计算 张楠 2019秋](#))

我们已经知道Monte Carlo积分方法可以用来估计 $E[g(X)]$ 这种类型的积分. 下面我们讨论如何减少 $\theta = E[g(X)]$ 的样本均值估计量.

若 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 为参数 θ 的两个估计量, 且 $Var(\hat{\theta}_2) < Var(\hat{\theta}_1)$, 则使用 $\hat{\theta}_2$ 比使用 $\hat{\theta}_1$ 方差的减少百分比为 $100 \left(\frac{Var(\hat{\theta}_1) - Var(\hat{\theta}_2)}{Var(\hat{\theta}_1)} \right)$. 尽管可以增加样本量 m 来减少方差, 但是计算成本会很高. 比如标准差要至多为 e , 而 $Var(g(X)) = \sigma^2$, 则需要样本量 $m \geq \frac{\sigma^2}{e^2}$. 如要把标准差从0.01减少到0.0001, 则样本量至少要10000.

Antithetic Variables

注意都对两个随机变量 U_1, U_2 ,

$$Var((U_1 + U_2)/2) = \frac{1}{4}(Var(U_1) + Var(U_2) + 2Cov(U_1, U_2)).$$

因此, 当 U_1, U_2 负相关时 $(U_1 + U_2)/2$ 的方差比其相互独立时要小. 这个事实促使我们考虑使用负相关的随机变量来减少方差.

比如, 假设 X_1, \dots, X_n 为通过逆变换方法生产的, 对此 m 个随机向量 $(X = (X_1, \dots, X_n))$ 的每一个, 我们已经产生 $U_j \sim U(0, 1)$ 以及计算 $X^{(j)} = F_X^{-1}(U_j), j = 1, \dots, n$. 注意到若 $U \sim U(0, 1)$, 则 $1 - U \sim U(0, 1)$, 而 U 与 $1 - U$ 负相关. 则

$$Y_j = g(X^{(j)}) = g(F_X^{-1}(U_1^{(j)}), \dots, F_X^{-1}(U_n^{(j)}))$$

与

$$Y'_j = g(X^{(j)}) = g(F_X^{-1}(1 - U_1^{(j)}), \dots, F_X^{-1}(1 - U_n^{(j)}))$$

同分布.

那么什么情形下 Y_j 与 Y'_j 是负相关的? 下面的定理说明如果 g 是单调的, 则 Y_j 和 Y'_j 是负相关的.

定义 $(x_1, \dots, x_n) \leq (y_1, \dots, y_n)$ 如果 $x_j \leq y_j, j = 1, \dots, n$. 一个 n 元函数 $g = g(x_1, \dots, x_n)$ 称为是增的, 如果其对每一个变量都是增的, 即如果 $(x_1, \dots, x_n) \leq (y_1, \dots, y_n)$, 则 $g(x_1, \dots, x_n) \leq g(y_1, \dots, y_n)$. 类似的称 g 为递减的, 如果其对每个变量都是减的. 最后, 称 g 是单调的, 如果其是增的或者减的.

定理: 设 $X = (X_1, \dots, X_n)$ 各分量相互独立, f 和 g 为同方向单调函数(同增或者同减), 则 $E[f(X)g(X)] \geq E[f(X)]E[g(X)]$.

证:

[折叠]

不妨设 f, g 同增. 证明方法是对 n 归纳. 假设 $n = 1$, 则对所有的 $x, y \in \mathcal{R}, (f(x) - f(y))(g(x) - g(y)) \geq 0$. 因此 $E[(f(X) - f(Y))(g(X) - g(Y))] \geq 0$, 即有

$$E[f(X)g(X)] + E[f(Y)g(Y)] \geq E[f(X)g(Y)] + E[f(Y)g(X)].$$

此处 X, Y i.i.d, 因此

$$\begin{aligned} 2E[f(X)g(X)] &= E[f(X)g(X)] + E[f(Y)g(Y)] \\ &\geq E[f(X)g(Y)] + E[f(Y)g(X)] = 2E[f(X)]E[g(X)], \end{aligned}$$

即结论对 $n = 1$ 成立. 现在假设对 $n - 1$ 成立, 则由于

$$\begin{aligned} E[f(X)g(X)|X_n = x_n] &\geq E[f(X_1, \dots, X_{n-1}, x_n)]E[g(X_1, \dots, X_{n-1}, x_n)] \\ &= E[f(X|X_n = x_n)]E[g(X|X_n = x_n)], \end{aligned}$$

最后一式每个为 X_n 的增函数, 因此根据 $n = 1$ 的结论有

$$\begin{aligned} E[f(X)g(X)] &= E\{E[f(X)g(X)|X_n]\} \\ &\geq E\{E[f(X|X_n = x_n)]\}E\{E[g(X|X_n = x_n)]\} \\ &= E[f(X)]E[g(X)]. \end{aligned}$$

□

推论: 设 $g = g(X_1, \dots, X_n)$ 是单调的, 则

$$Y = g(F_X^{-1}(U_1), \dots, F_X^{-1}(U_n))$$

与

$$Y' = g(F_X^{-1}(1 - U_1), \dots, F_X^{-1}(1 - U_n))$$

是负相关的.

证:

[折叠]

不失一般性, 假设 g 是递增的. 则

$$Y = g(F_X^{-1}(U_1), \dots, F_X^{-1}(U_n))$$

与

$$-Y' = f = -g(F_X^{-1}(1 - U_1), \dots, F_X^{-1}(1 - U_n))$$

是两个递增的函数. 因此 $E[g(U)f(U)] \geq E[g(U)]E[f(U)]$, 即 $E[YY'] \leq E[Y]E[Y']$, 此即意味着

$$\text{Cov}(Y, Y') = E[YY'] - E[Y]E[Y'] \leq 0.$$

从而 Y 和 Y' 负相关.

□

对偶变量(Antithetic Variables)方法很容易应用. 如果需要 m 个Monte Carlo重复, 则产生 $m/2$ 个重复

$$Y_j = g(F_X^{-1}(U_1^{(j)}), \dots, F_X^{-1}(U_n^{(j)}))$$

以及剩下 $m/2$ 个重复

$$Y'_j = g(F_X^{-1}(1 - U_1^{(j)}), \dots, F_X^{-1}(1 - U_n^{(j)})),$$

其中 $U_i^{(j)}, i = 1, \dots, n; j = 1, \dots, m/2$. *i.i.d* $U(0, 1)$. 则对偶估计量为

$$\begin{aligned}\hat{\theta} &= \frac{1}{m} \{Y_1 + Y'_1 + Y_2 + Y'_2 + \dots + Y_{m/2} + Y'_{m/2}\} \\ &= \frac{2}{m} \sum_{j=1}^{m/2} \frac{Y_j + Y'_j}{2}.\end{aligned}$$

通过使用对偶变量使得得到的Monte Carlo 估计的方差减少.

例6: 对偶变量方法使用之前的例子, 比如要估计积分

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt.$$

使用对偶变量方法估计此积分, 并找出标准差的减少量.

作变量代换后, 目标积分是 $\theta = E_U[xe^{-(xU)^2/2}]$, 其中 $U \sim U(0, 1)$. 显然此处 g 函数是单调的, 因此前面推论的条件满足. 产生随机数 $u_1, \dots, u_{m/2} \sim U(0, 1)$, 计算

$$Y_j = g^{(j)}(u) = xe^{-(xu_j)^2/2}, j = 1, \dots, m/2.$$

以及

$$Y'_j = xe^{-(x(1-u_j))^2/2}, j = 1, \dots, m/2.$$

则样本均值

$$\hat{\theta} = \overline{g_m(u)} = \frac{1}{m/2} \sum_{j=1}^{m/2} \frac{xe^{-(u_j x)^2} + xe^{-(x(1-u_j))^2/2}}{2}$$

收敛到 $E\hat{\theta}$.

从而若 $x > 0$, 则 $\Phi(x)$ 的估计为 $0.5 + \hat{\theta}/\sqrt{2\pi}$; 若 $x < 0$, 则 $\Phi(x) = 1 - \Phi(-x)$.

```
MC.Phi <- function(x, R = 10000, antithetic = TRUE) {
  u <- runif(R/2)
  if (!antithetic) v <- runif(R/2) else
    v <- 1 - u
  u <- c(u, v)
  cdf <- numeric(length(x))
  for (i in 1:length(x)) {
    g <- x[i] * exp(-(u * x[i])^2 / 2)
    cdf[i] <- mean(g) / sqrt(2 * pi) + 0.5
  }
  cdf
}
```

和简单的Monte Carlo积分方法相比较:

```
x <- seq(.1, 2.5, length=5)
Phi <- pnorm(x)
set.seed(123)
MC1 <- MC.Phi(x, anti = FALSE)
```

```
set.seed(123)
MC2 <- MC.Phi(x)
print(round(rbind(x, MC1, MC2, Phi), 5))
```

方差的减少量可以模拟来比较:

```
m <- 1000
MC1 <- MC2 <- numeric(m)
x <- 1.95
for (i in 1:m) {
  MC1[i] <- MC.Phi(x, R = 1000, anti = FALSE)
  MC2[i] <- MC.Phi(x, R = 1000)
}
print(sd(MC1))
print(sd(MC2))
print((var(MC1) - var(MC2))/var(MC1))
```

对 $x = 1.95$, 对偶变量方法相比于简单Monte Carlo方法估计的方差大约减少99.5%.

取自 ["http://shjkx.wang/index.php?title=统计计算_张楠_2019秋: Variance Reduction: Antithetic Variables&oldid=157211"](http://shjkx.wang/index.php?title=统计计算_张楠_2019秋:_Variance_Reduction:_Antithetic_Variables&oldid=157211)

本页面最后编辑于2019年9月24日 (星期二) 22:40。