## 统计计算 张楠 2019秋: Bootstrap Confidence Intervals

(返回 统计计算 张楠 2019秋)

本节中我们介绍几种在Bootstrap中构造目标参数的渐近置信区间的方法,其中包括标准正态Bootstrap置信区间,基本的Bootstrap置信区间,Bootstrap百分位数(percentile)置信区间和Bootstrapt 置信区间.

### The Standard Normal Bootstrap Confidence Interval

# 标准正态Bootstrap置信区间是一种比较简单的方法. 假设 $\hat{ heta}$ 是参数 heta 的估计量,以及估计量的标准差为 $se(\hat{ heta})$ . 若 $\hat{ heta}$ 渐近到正态分布,即 $Z=rac{\hat{ heta}-E\hat{ heta}}{se(\hat{ heta})}$ 渐近服从标准正态分

#### 目录

The Standard Normal Bootstrap Confidence Interval

The Percentile Bootstrap Confidence Interval

The Basic Bootstrap Confidence Interval

The Bootstrap t interval

布. 则若 $\hat{\theta}$ 为 $\theta$ 的无偏估计,那么 $\theta$ 的一个渐近的 $100(1-\alpha)$ % 标准正态 Bootstrap 置信区间为  $\hat{\theta}$  ±  $z_{\alpha/2}$   $\hat{se}_B(\hat{\theta})$ ,其中  $z_{\alpha/2} = \Phi^{-1}(1-\alpha/2)$ . 此区间容易计算,但是有正态性假设或者CLT需成立. 以及  $\hat{\theta}$ 为 $\theta$ 的无偏估计.

#### The Percentile Bootstrap Confidence Interval

由形式  $P(L \leq \hat{\theta} \leq U) = 1 - \alpha$  知, 可以使用Bootstrap重复的样本百分位数来估计L和U. 而 $\hat{\theta}$ 为 $\theta$ 的估计, 因此就取  $\theta$ 的 $1 - \alpha$ 置信区间上下界分别为Bootstrap重复的样本 $1 - \alpha/2$ 百分位数 $\hat{\theta}^*_{[(B+1)(1-\alpha/2)]}$  和 $\alpha/2$ 百分位数 $\hat{\theta}^*_{[(B+1)\alpha/2]}$ .

Efron & Tibshirani 证明了百分位数区间相比于标准正态区间有着更好的理论覆盖率. 下面我们还会介绍 bias-corrected and accelerated(BCa) 百分位数区间,它是百分位数区间的一个修正版本,有着更好的理论性质以及在应用中有着更好的覆盖率.

#### The Basic Bootstrap Confidence Interval

由  $P(L < \hat{\theta} - \theta < U) = 1 - \alpha$  在 $\hat{\theta} - \theta$  的分布未知时,由于Bootstrap 重复 $\hat{\theta}^*$  的样本分位数 $\hat{\theta}^*_{[(B+1)\alpha/2]}$ 和 $\hat{\theta}^*_{[(B+1)(1-\alpha/2)]}$ 满足 $P(\hat{\theta}^*_{[(B+1)\alpha/2]} - \hat{\theta} \leq \hat{\theta} - \theta \leq \hat{\theta}^*_{[(B+1)(1-\alpha/2)]} - \hat{\theta}) \approx 1 - \alpha$ . 因此 $100(1-\alpha)$ %置信区间为 $(2\hat{\theta} - \hat{\theta}^*_{[(B+1)(1-\alpha/2)]}, 2\hat{\theta} - \hat{\theta}^*_{[(B+1)\alpha/2]})$  boot包里的函数boot.ci计算五种类型的置信区间:基本的,正态,百分位数,Bootstrap t和BCa.

例11 patch数据比值统计量的Bootstrap 置信区间

本例说明如何使用boot和boot.ci函数得到正态,基本的和百分位数 Bootstrap置信区间. 下面的代码计算 比值统计量的 95%置信区间.

```
library(boot)  #for boot and boot.co
data(patch, package = "bootstrap")
theta.boot <- function(dat, ind) {
    #function to compute the statistic
    y <- dat[ind, 1]
    z <- dat[ind, 2]
    mean(y) / mean(z)
}</pre>
```

注意当 $|\theta|$  < 0.2时,旧药和新药才被认为是等价的. 因此区间估计没有支持旧药和新药的等价性. 下面 我们根据Bootstrap 置信区间的定义计算置信区间,和上面的结果相对比.

```
#calculations for bootstrap confidence intervals
alpha <- c(.025, .975)
#normal
print(boot.obj$t0 + qnorm(alpha) * sd(boot.obj$t))
#basic
print(2*boot.obj$t0 -
    quantile(boot.obj$t, rev(alpha), type=1))
#percentile
print(quantile(boot.obj$t, alpha, type=6))</pre>
```

例12 patch数据中相关系数的Bootstrap置信区间 对law数据, 计算相关统计量的95%置信区间.

三种置信区间都覆盖住了 $\rho = .76$ (此时通过完整数据集law82计算的). 百分位数置信区间和正态 置信区间的差异在于样本相关系数的分布是不是靠近正态分布. 当统计量的分布很靠近正态时, 百分位数 区间和正态区间就会一致.

#### The Bootstrap t interval

即使当 $\hat{\theta}$ 的分布是正态分布,且 $\hat{\theta}$ 为 $\theta$ 的无偏估计, $Z=(\hat{\theta}-\theta)/se(\hat{\theta})$ 的分布也不会一定是正态的,这是因为我们估计了 $se(\hat{\theta})$ . 我们也不能说Z的分布是t分布,因为 Bootstrap估计 $\hat{s}e(\hat{\theta})$ 的分布未知. Bootstrap t区间并没有使用t分布作为推断分布. 而是使用 再抽样方法得到一个"t类型"的统计量的分布. 假设 $x=(x_1,\ldots,x_n)$ 为观测到得样本,则 $100(1-\alpha)\%$  Bootstrap t 置信区间为  $(\hat{\theta}-t_{1-\alpha/2}^*\hat{s}e(\hat{\theta}),\hat{\theta}-t_{\alpha/2}^*\hat{s}e(\hat{\theta}))$  其中 $\hat{s}e(\hat{\theta}),t_{\alpha/2}^*$  和 $t_{1-\alpha/2}^*$ 由下面的方法计算:

#### Bootstrap t 区间

- 1. 计算观测到得 $\hat{\theta}$ .
- 2. 对每个重复,  $b = 1, \dots, B$ :
  - 1. 从x中有放回的抽样得到第b个样本 $x^{(b)}=(x_1^{(b)},\dots,x_n^{(b)})$
  - 2. 由第b个再抽样样本计算 $\hat{ heta}^{(b)}$
  - 3. 计算标准差估计 $\hat{se}(\hat{ heta}^{(b)})$ .(对每个Bootstrap样本 $x^{(b)}$ , 再单独进行一个Bootstrap估计).
  - 4. 计算第b个重复下的"t"统计量:  $t^{(b)} = (\hat{ heta}^{(b)} \hat{ heta})/\hat{se}(\hat{ heta}^{(b)})$ .
- 3. 重复样本 $t^{(1)},\dots,t^{(B)}$ 的分布作为推断分布. 找出样本分位数 $t^*_{lpha/2}$ 和 $t^*_{1-lpha/2}$ .
- 4. 计算 $\hat{se}(\hat{ heta})$ , 即Bootstrap重复 $\{\hat{ heta}^{(b)}\}$ 的样本标准差.
- 5. 计算置信界  $(\hat{ heta}-t^*_{1-lpha/2}\hat{se}(\hat{ heta}),\hat{ heta}-t^*_{lpha/2}\hat{se}(\hat{ heta}))$  .

Bootstrap t区间的一个缺点是要再次使用Bootstrap方法得到标准差的估计 $\hat{se}(\hat{\theta}^{(b)})$ . 这是在Bootstrap 里面嵌套Bootstrap. 若B=1000,则Bootstrap t区间方法需要比别的方法1000倍的时间.

例13 Bootstrap t区间 本例我们写一个函数来计算一元或者多元样本下Bootstrap t 置信区间. 默认的置信水平为95%, Bootstrap重复数为500, 估计标准差的重复次数默认为100.

```
boot, t, ci <-
   function (x, B = 500, R = 100, level = .95, statistic) {
        #compute the bootstrap t CI
       x \leftarrow as. matrix(x); n \leftarrow nrow(x)
       stat <- numeric(B); se <- numeric(B)
       boot.se \leftarrow function(x, R, f) {
            #local function to compute the bootstrap
            #estimate of standard error for statistic f(x)
            x \leftarrow as. matrix(x); m \leftarrow nrow(x)
            th <- replicate(R, expr = {
                 i <- sample(1:m, size = m, replace = TRUE)
                 f(x[i, ])
                 })
            return(sd(th))
       for (b in 1:B) {
            j <- sample(1:n, size = n, replace = TRUE)</pre>
            y <- x[j, ]
            stat[b] <- statistic(y)</pre>
            se[b] \leftarrow boot.se(y, R = R, f = statistic)
       stat0 <- statistic(x)
       t. stats <- (stat - stat0) / se
       se0 <- sd(stat)
       alpha <- 1 - level
       Qt \leftarrow quantile (t. stats, c(alpha/2, 1-alpha/2), type = 1)
       names(Qt) \leftarrow rev(names(Qt))
       CI \leftarrow rev(stat0 - Qt * se0)
```

例14 patch数据下比值统计量的Bootstrap t 置信区间

程序如下:

```
#boot package and patch data were loaded in Example 7.10
#library(boot) #for boot and boot.ci
#data(patch, package = "bootstrap")
dat <- cbind(patch$y, patch$z)
stat <- function(dat) {
    mean(dat[, 1]) / mean(dat[, 2]) }
ci <- boot.t.ci(dat, statistic = stat, B=2000, R=200)
print(ci)</pre>
```

取自 "http://shjkx.wang/index.php?title=统计计算 张楠 2019 秋: Bootstrap Confidence Intervals&oldid=161447"

本页面最后编辑于2019年11月6日 (星期三) 11:48。